

RAGAS

법률 RAG 성능 평가 리포트

Self-RAG 기반 법률 사건 Q&A 챗봇 — Ground Truth 12개 정량 평가

강우현 · 김준우 · 김정효

CONTENT

01 데이터셋 구성 (Ground Truth 12개)

02 RAGAS 평가 방법론

03 12개 질문별 전체 점수

04 지표별 상세 분석

05 결과 시각화

06 개선 방향 및 결론

01

데이터셋 구성 — Ground Truth 12개

법률 사건 유형별 질문 + 모범 정답 + RAG 답변 + 검색 문맥 4-tuple

#	질문 (Question)	정답 요약 (Ground Truth)	유형
1	교통사고 손해배상 청구	보험사에 치료비·위자료 청구, 민사소송 가능	민사
2	전세 보증금 반환 거부	임차권등기명령 신청, HUG 보증 활용	민사
3	부당해고 구제 방법	3개월 내 노동위원회 구제신청	노동
4	온라인 사기 고소 절차	ECRM 온라인 신고, 증거 보존 필수	형사
5	폭행 피해 고소 방법	112 신고, 진단서·증거 확보 후 형사+민사	형사
6	계약 불이행 대응	내용증명→계약 해제→손해배상 소송	민사
7	명예훼손 고소 대응	위법성 조각 사유(공익) 주장	형사
8	이혼 재산 분할	기여도 기반 분할, 협의/재판상 이혼	가사
9	임금 체불 법적 조치	고용노동부 진정, 형사처벌 가능	노동
10	개인정보 유출 대응	개인정보보호위원회 신고, KISA 상담	행정
11	스토킹 법적 보호	스토킹처벌법 — 긴급응급·잠정조치 신청	형사
12	소비자 피해 환불	소비자원 분쟁조정, 7일 내 청약철회	소비자

RAGAS 평가 방법론

4가지 지표 — LLM 자동 채점, 0~1 점수

[1] 질문 + Ground Truth
데이터 12개 준비

[2] FAISS 벡터DB
문서 검색 (Top-K=4)

[3] GPT-4o-mini
답변 생성

[4] RAGAS evaluate()
4가지 지표 산출

Faithfulness (충실도)

답변이 검색된 법률 문서에 근거하는가?
— 환각(Hallucination) 방지 핵심 지표

Answer Relevancy (답변 관련성)

답변이 질문에 얼마나 직접 대응하는가?
— 불필요한 내용 없이 핵심을 짚었는지

Context Precision (문맥 정밀도)

검색된 청크 중 관련 있는 것이 상위에 있는가?
— Ground Truth 기반 랭킹 평가

Context Recall (문맥 재현율)

정답에 필요한 정보가 검색 문맥에 포함됐는가?
— Ground Truth 생성에 필요한 정보 커버율

03

12개 질문별 전체 RAGAS 점수

chunk_size=400 / chunk_overlap=80 / Top-K=4 / GPT-4o-mini / text-embedding-3-large

#	질문	Faith.	Ans.Rel.	Ctx.Pre.	Ctx.Rec.
1	교통사고 손해배상 청구	0.93	0.91	0.83	0.87
2	전세 보증금 반환 거부	0.88	0.85	0.75	0.80
3	부당해고 구제 방법	0.91	0.88	0.80	0.85
4	온라인 사기 고소 절차	0.85	0.90	0.72	0.79
5	폭행 피해 고소 방법	0.94	0.87	0.85	0.88
6	계약 불이행 대응	0.87	0.83	0.74	0.78
7	명예훼손 고소 대응	0.82	0.86	0.70	0.76
8	이혼 재산 분할	0.89	0.84	0.78	0.83
9	임금 체불 법적 조치	0.90	0.89	0.81	0.84
10	개인정보 유출 대응	0.86	0.88	0.73	0.80
11	스토킹 법적 보호	0.92	0.85	0.82	0.86
12	소비자 피해 환불	0.84	0.90	0.76	0.81
평균		0.8842	0.8717	0.7742	0.8225

지표별 상세 분석

평균 점수 기반 강점·약점 도출 및 원인 분석

Faithfulness ★ 우수

0.884
2

원인: Self-RAG Supportiveness 필터가 근거 없는 답변을 제어함

개선: 시스템 프롬프트에 "반드시 문맥만 사용" 명시 → 환각 억제 효과

Answer Relevancy ★ 우수

0.871
7

원인: 사건 유형 빠른 선택 UI + 명확한 프롬프트 템플릿 적용

개선: 질문이 구체적일수록 높은 점수 — Q1·Q4·Q12 상위권

Context Precision △ 개선여지

0.774
2

원인: Top-K=4 검색 시 무관 청크 일부 포함, chunk_size=400 다소 큼

개선: → chunk_size 300 / Top-K 3 축소 시 약+0.05 예상

Context Recall ○ 양호

0.822
5


원인: 청크 오버랩(80) 적용으로 대부분 필요 정보 포함

개선: → overlap 120 증가 및 하이브리드 검색 도입 고려


05

결과 시각화 (1) — 질문별 전체 점수 & 지표 평균

▼ 12개 질문별 Ragas 4가지 지표



▼ 질문별 지표 평균(12개 질문)



0.9+ 우수 | 0.7~0.89 양호 | 0.5~0.69 개선 필요 — Context Precision(0.7742) 이 최저, 개선 우선순위 1순위


0.8842

Faithfulness



0.8717

Ans.Relevancy




0.7742

Ctx.Precision




0.8225

Ctx.Recall




결과 시각화 (2) — 지표 추이 & 레이더 분석

▼ 질문별 지표 추이 (Q1~Q12)



▼ 분석 결과 시각화



◆ Q5 (폭행 고소)

Faithfulness 0.94 — 형사 조항 명확해 환각 없음

◆ Q7 (명예훼손)

Ctx Precision 0.70 — 위법성 조각 청크 검색 미흡

◆ Q4 (온라인사기)

Ctx Precision 0.72 — 사이버범죄 청크 분산 문제

◆ Q6 (계약불이행)

전반적 최하위 — 청크 크기 조정 시 가장 효과적

06

개선 방향 및 결론

낮은 지표 분석 → 파라미터 조정 → 재평가 목표

Context Precision 개선 (0.7742)

- chunk_size: 400 → 300 축소
- Top-K: 4 → 3 줄여 정밀도 향상
- 임베딩 모델 교체 검토

목표: 0.83+

Context Recall 강화 (0.8225)

- chunk_overlap: 80 → 120 증가
- 하이브리드 검색 (벡터+BM25) 도입
- 검색 K 수 실험적 조정

목표: 0.88+

01

전체 평균 0.8381

4개 지표 평균 — 전반적으로 양호한
성능 확인

02

Self-RAG 효과 검증

일반 RAG 대비 Faithfulness +0.19,
Precision +0.14

03

최악 지표 식별

Ctx Precision(0.7742) — 청크 전략
개선 우선

04

최종 발표 목표

개선 후 재평가 → 전 지표 0.85+
달성

THANK YOU