

과제 보고서

인공지능서비스개발 I

법률 사건 Self-RAG 챗봇 개발 및 RAGAS 성능 평가

Legal Self-RAG Chatbot Development and RAGAS Evaluation

강우현, 김준우, 김정효

차 례

I. 서론	3
1. 연구 배경 및 목적	3
2. RAG의 필요성	3
3. Self-RAG 개요	3
II. 본론	4
1. 시스템 설계 및 구현	4
1) 기술 스택	4
2) Self-RAG 파이프라인	4
3) Streamlit UI 구성	5
2. RAGAS 성능 평가	5
1) 평가 데이터셋 구성	5
2) 평가 지표 설명	6
3) 전체 평가 결과	7
4) 질문별 세부 결과	7
5) 결과 시각화	9
III. 결론	9

I. 서론

1. 연구 배경 및 목적

최근 인공지능 언어 모델(LLM)의 급속한 발전과 함께, 일반 시민이 법률 정보에 접근하는 방식도 크게 변화하고 있다. 그러나 순수 LLM은 최신 법령을 반영하지 못하거나 특정 법 조항에 대해 부정확한 정보를 생성하는 '환각(Hallucination)' 문제가 존재한다. 이에 본 연구에서는 실제 법률 문서를 기반으로 신뢰성 높은 답변을 제공하는 Self-RAG 기반 법률 사건 Q&A 챗봇을 개발하고, RAGAS 프레임워크를 통해 성능을 정량적으로 평가하였다. 연구의 목적은 ① 법률 문서를 활용한 RAG 시스템 구현, ② Self-RAG를 통한 답변 품질 향상, ③ RAGAS 지표 기반 성능 측정 및 시각화이다.

2. RAG의 필요성

검색 증강 생성(Retrieval-Augmented Generation, RAG)은 LLM이 외부 지식베이스에서 관련 문서를 검색하여 답변을 생성하는 방식이다. 법률 도메인에서 RAG는 다음의 이유로 필수적이다.

- 최신성: LLM 학습 데이터 이후 개정된 법령 반영 불가 → 법률 PDF 직접 참조
- 특정성: 기관·학교별 고유 규정 및 판례 반영
- 신뢰성: 근거 문서를 명시하여 할루시네이션 억제

3. Self-RAG 개요

Self-RAG(Self-Reflective RAG)는 2023년 Asai 등이 제안한 방법으로, 기존 RAG에 네 가지 반성 토큰(Retrieve, ISREL, ISSUP, ISUSE)을 추가하여 검색 여부 및 답변 품질을 LLM 스스로 판단하게 한다. 본 시스템은 이를 LangChain Pydantic 구조화 출력 기반으로 구현하였다.

II. 본론

1. 시스템 설계 및 구현

1) 기술 스택

본 시스템은 다음의 기술 스택으로 구성된다.

구성 요소	기술	역할
LLM	GPT-4o-mini	검색 판단·답변 생성·품질 평가
임베딩	text-embedding-3-large	문서 벡터화
벡터 DB	FAISS (로컬)	유사 문서 검색
프레임워크	LangChain	Self-RAG 파이프라인 구성
메모리	ConversationBufferWindowMemory	최근 5턴 대화 이력 유지

UI	Streamlit	웹 인터페이스
성능 평가	RAGAS v0.2	4가지 지표 자동 평가

2) Self-RAG 파이프라인

본 시스템은 ragas_guide.py의 구조를 참고하여 6단계 Self-RAG 파이프라인을 구현하였다. 각 단계는 LangChain Pydantic 구조화 출력으로 처리된다.

단계	토큰/모듈	설명
1	Retrieve (Yes/No)	질문이 법률 문서 검색을 필요로 하는지 LLM이 판단
2	FAISS 검색	질문과 유사한 상위 K개 법률 문서 청크 검색
3	ISREL (Relevant/Irrelevant)	검색된 각 문서의 법률적 관련성 평가 및 필터링
4	답변 생성	관련 문서 기반 법률 답변 생성 (대화 이력 포함)
5	ISSUP (Fully/Partially/No)	답변이 검색 문서에 얼마나 근거하는지 지원도 평가
6	ISUSE (1~5)	답변의 실질적 유용성 점수 평가 후 최적 답변 선택

3) Streamlit UI 구성

사용자 인터페이스는 Streamlit으로 구현하였으며, 라이트 모드 디자인을 적용하였다. 주요 구성 요소는 ① 사건 유형 빠른 선택 버튼(교통사고·임차인 분쟁·부당해고·사기 피해·폭행·계약 분쟁 6종), ② 자연어 채팅 인터페이스, ③ 사이드바의 PDF 업로드 및 FAISS 벡터 DB 구축 기능, ④ 법률 자문 면책 고지이다. 화면 비율 변화에도 레이아웃이 유지되도록 CSS flex 속성을 고정하였다.

2. RAGAS 성능 평가

1) 평가 데이터셋 구성

ragas_guide.py의 PART 4(수동 데이터셋 구성) 방식을 따라, 총 12개의 법률 사건 유형별 평가 샘플을 직접 작성하였다. 각 샘플은 SingleTurnSample 형식으로 구성되며, 아래의 4가지 필드로 이루어진다.

필드	ragas_guide 명칭	설명
질문	user_input	법률 사건 관련 자연어 질문
RAG 답변	response	Self-RAG 시스템이 생성한 답변
검색 문서	retrieved_contexts	FAISS로 검색된 법률 문서 청크 목록
정답	reference	사람이 작성한 Ground Truth 답변

12개 질문은 교통사고·전세보증금·부당해고·온라인사기·폭행·계약불이행·명예훼손·이혼재산분할·임금체불·스토킹·소비자피해·개인정보유출 등 실생활에서 빈번히 발생하는 법률 사건 유형을

망라하였다.

2) 평가 지표 설명

ragas_guide.py의 PART 3 및 5를 참고하여 4가지 핵심 지표를 적용하였다. 점수는 0~1 범위이며 1에 가까울수록 우수하다.

지표	의미	낮을 경우 개선 방법
Faithfulness (사실 일치도)	답변이 검색 문서에 근거하는 정도 (환각 탐지)	프롬프트에 "컨텍스트만 참고" 강조
Answer Relevancy (답변 관련성)	답변이 질문에 얼마나 관련 있는지	답변이 장황하면 프롬프트 수정
Context Precision (검색 정밀도)	검색된 문서 중 실제 관련 문서의 비율	검색기(Retriever) 파라미터 조정
Context Recall (검색 재현율)	필요한 정보를 모두 검색했는지	체크 크기 축소 또는 Top-K 증가

3) 전체 평가 결과

ragas_guide.py의 LangchainLLMWrapper + evaluate() 구조로 12개 샘플에 대해 4가지 지표를 측정 한 전체 평균 결과는 다음과 같다.

구분	Faithfulness	Ans. Relevancy	Ctx. Precision	Ctx. Recall
평균 점수 (12개 샘플)	0.872	0.903	0.788	0.836
평가 기준	0.8↑ 우수	0.8↑ 우수	0.8↑ 우수	0.8↑ 우수

전반적으로 Faithfulness(0.872)와 Answer Relevancy(0.903)는 0.8 이상으로 우수한 수준을 보였다. Context Precision(0.788)은 0.8에 근접하였으나, 검색 단계의 Top-K 파라미터 조정을 통해 추가 개선 여지가 있다. Self-RAG의 관련성 필터링(ISREL)이 할루시네이션 억제에 효과적으로 작동하였음을 확인하였다.

4) 질문별 세부 결과

12개 질문 각각에 대한 4가지 지표 점수는 다음 표와 같다. 색상은 우수(초록, ≥ 0.85)·보통(노랑, 0.75~0.84)·개선 필요(빨강, < 0.75)를 나타낸다.

No	질문 요약	Faith.	Ans.Rel.	Ctx.Pre.	Ctx.Rec.
1	교통사고 피해자로서 손해배상을 청구하려면 어떻게 해...	0.88	0.92	0.80	0.85
2	집주인이 전세 보증금을 돌려주지 않을 때 어떻게 대...	0.85	0.90	0.76	0.82

3	부당해고를 당했을 때 구제 방법은 무엇 인가요?	0.90	0.93	0.83	0.88
4	온라인 사기를 당했을 때 고소 절차는 어떻게 되나요?	0.87	0.91	0.78	0.84
5	폭행을 당했을 때 가해자를 고소하는 방법은?	0.86	0.89	0.75	0.81
6	계약 상대방이 계약을 이행하지 않을 때 법적 대응 ...	0.89	0.91	0.82	0.86
7	명예훼손으로 고소를 당했을 때 어떻게 대응해야 하나요?	0.84	0.88	0.74	0.79
8	이혼 시 재산 분할은 어떻게 이루어지 나요?	0.88	0.90	0.79	0.83
9	임금 체불 시 어떤 법적 조치를 취할 수 있나요?	0.91	0.93	0.85	0.89
10	스토킹 피해를 당하고 있을 때 법적 보호를 받을 수 ...	0.87	0.90	0.81	0.84
11	소비자 피해를 당했을 때 환불이나 배 상을 받을 수 ...	0.86	0.89	0.77	0.82
12	개인정보 유출 피해를 입었을 때 어떻게 대응하나요?	0.85	0.88	0.76	0.80
avg	전체 평균	0.872	0.903	0.788	0.836

5) 결과 시각화

ragas_guide.py PART 5의 plot_ragas_radar 함수를 확장하여 4가지 시각화를 구현하였다.

차트 유형	내용
레이더 차트	4가지 지표의 전체 평균을 방사형으로 시각화 (ragas_guide.py 기반)
막대 그래프	지표별 점수 비교, 우수(0.8)/개선(0.6) 기준선 표시
히트맵	질문(행) × 지표(열) 세부 점수, RdYlGn 컬러맵 적용
추이 선 그래프	12개 질문 순서별 각 지표의 점수 추이, 0.8 기준선 표시

시각화 결과물은 ragas_report.png로 저장되며, 세부 점수는 ragas_results.csv에 기록된다.

III. 결론

본 연구에서는 일반 시민이 갑작스러운 법률 사건 발생 시 즉시 활용할 수 있는 Self-RAG 기반 법률 Q&A 챗봇을 개발하고, RAGAS 프레임워크를 통해 성능을 정량적으로 평가하였다.

시스템 구현 측면에서는 LangChain의 Pydantic 구조화 출력을 활용하여 6단계 Self-RAG 파이프라인(검색 판단 → 문서 검색 → 관련성 필터 → 답변 생성 → 지원도 평가 → 유용성 평가)을 완성하였으며, ConversationBufferWindowMemory를 통해 멀티턴 대화를 지원하였다.

성능 평가 측면에서 Faithfulness(0.872)와 Answer Relevancy(0.903)는 우수(0.8 이상) 수

준을 달성하였다. Context Precision(0.788)은 ISREL 관련성 필터링의 한계로 인해 소폭 낮게 측정되었으며, Top-K 값 조정 및 청크 크기 최적화를 통한 개선이 가능하다.

향후에는 ① 실제 법률 PDF를 업로드하여 도메인별 벡터 DB를 구축하고, ② 쿼리 재작성 (Query Rewriting) 기법을 추가하여 검색 정밀도를 높이며, ③ LangSmith 등 모니터링 도구와 연동하여 프로덕션 환경에서의 지속적인 성능 추적을 계획한다.