

법률 사건 Q&A Self-RAG 챗봇 개발 및 RAGAS 성능 평가

Legal Case Q&A Self-RAG Chatbot Development and RAGAS Evaluation

강우현, 김준우, 김정호

강남대학교

1. 연구 배경

- 연구의 필요성

최근 인공지능 언어 모델(LLM)의 급속한 발전과 함께, 일반 시민이 법률 정보에 접근하는 방식도 크게 변화하고 있다. 그러나 순수 LLM은 최신 법령을 반영하지 못하거나 특정 법 조항에 대해 부정확한 정보를 생성하는 '환각(Hallucination)' 문제가 존재한다.

- 기존 연구

Self-RAG는 기존 RAG에 네 가지 반성 토큰(Retrieve, ISREL, ISSUP, ISUSE)을 추가하여 검색 여부 및 답변 품질을 LLM 스스로 판단하게 한다. RAGAS 프레임워크는 Faithfulness, Answer Relevancy, Context Precision, Context Recall 4가지 지표로 RAG 시스템을 정량 평가한다.

- 연구 목표

본 연구는 ① 법률 문서를 활용한 Self-RAG 시스템 구현, ② RAGAS 지표 기반 성능 측정 및 시각화, ③ 할루시네이션 억제 효과 검증을 목적으로 한다.

2. 연구 내용

- 시스템 설계 및 구현

본 시스템은 GPT-4o-mini(LLM), text-embedding-3-large(임베딩), FAISS(벡터 DB), LangChain(파이프라인), Streamlit(UI), RAGAS v0.2(평가)로 구성된다.

- Self-RAG 파이프라인

6단계 파이프라인: ① Retrieve 판단 → ② FAISS 검색 → ③ ISREL 관련성 필터 → ④ 답변 생성 → ⑤ ISSUP 지원도 평가 → ⑥

4. 기대효과 및 활용

- 기존 기술과 비교한 우월성 및 차별성

순수 LLM 대비 Self-RAG는 문서 기반 답변 생성으로 할루시네이션을 억제하고 신뢰성을 향상시킨다. Faithfulness 0.872, Answer Relevancy 0.903으로 우수 기준(0.8↑)을 달성하였으며, 기존 단순 RAG 대비 ISREL 관련성 필터로 검색 품질이 향상되었다.

- 일반적 기대효과와 활용방안

일반 시민의 법률 접근성 향상, 24시간 즉시 법률 정보 제공, 법률 비용 절감 효과가 기대된다. 향후 쿼리 재작성(Query Rewriting) 기법 추가 및 LangSmith 연동을 통한 프로덕션 모니터링을 계획한다.

5. 결론

- 연구 성과의 핵심 내용

법률 사건 Self-RAG Q&A 챗봇을 개발하고 RAGAS로 정량 평가하였다. Faithfulness(0.872)와 Answer Relevancy(0.903)는 우수 수준을 달성하였으며, Self-RAG의 ISREL 관련성 필터링이 할루시네이션 억제에 효과적으로 작동함을 확인하였다.

- 본 주제의 향후 연구(보완) 계획

① 실제 법률 PDF 업로드를 통한 도메인별 벡터 DB 구축, ② Query Rewriting 기법 적용으로 Context Precision 개선, ③ LangSmith 연동을 통한 지속적 성능 추적을 계획한다.

ISUSE 유용성 평가. 각 단계는 LangChain Pydantic 구조화 출력으로 처리된다.

- Streamlit UI 구성

사건 유형 빠른 선택 버튼 6종(교통사고·임차인 분쟁·부당해고·사기 피해·폭행·계약 분쟁), 자연어 채팅 인터페이스, PDF 업로드 및 FAISS 벡터 DB 구축 기능, 법률 자문 면책 고지로 구성된다.

- RAGAS 성능 평가

교통사고·전세보증금·부당해고 등 12개 법률 사건 유형별 평가 샘플을 직접 작성하여 SingleTurnSample 형식으로 구성하였다. LangchainLLMWrapper + evaluate() 구조로 4가지 지표를 측정하였다.

표 1. RAGAS 전체 평균 평가 결과

지표	Faith.	Ans.Rel.	Ctx.Pre.	Ctx.Rec.
평균(12개)	0.872	0.903	0.788	0.836
기준	0.8↑	0.8↑	0.8↑	0.8↑

- 실험(동작 테스트) 내용

레이더 차트, 막대 그래프, 히트맵(RdYlGn), 추이 선 그래프의 4종 시각화를 구현하였으며, 세부 점수는 ragas_results.csv에 기록되고 결과물은 ragas_report.png로 저장된다.

표 2. 시스템 기술 스택

구성 요소	기술	역할
LLM	GPT-4o-mini	검색 판단·답변 생성
임베딩	text-embedding-3-large	문서 벡터화
벡터 DB	FAISS	유사 문서 검색
프레임워크	LangChain	Self-RAG 파이프라인
UI	Streamlit	웹 인터페이스
성능 평가	RAGAS v0.2	4가지 지표 자동 평가

3. 현적 제한 조건에 대한 검토

- 검색 정밀도 한계

Context Precision(0.788)이 0.8 미만으로 측정되어 ISREL 필터링의 한계가 존재한다. Top-K 파라미터 조정 및 청크 크기 최적화를 통한 개선이 필요하다.

- 법률 전문성 한계

GPT-4o-mini 기반으로 실제 법률 해석에는 전문가 검토가 필요하며, 시스템 내 법률 자문 면책 고지를 필수적으로 제공한다

참고 문헌

[1] langchain-tutorial, <https://github.com/langchain-kr/langchain-tutorial>, 2025.